

# Segmentarea Tumorilor

1<sup>st</sup> Chirca Radu-Iulian  
1310B

2<sup>nd</sup> Ionescu Razvan  
1310B


## I. INTRODUCTION

Segmentarea imaginilor medicale (procedura de impartire a unei magini digitale intr-un set multiplu de pixeli) este procesul de detectare automata sau semi-automata a limitelor dintr-o imagine 2D sau 3D. In plus, multe modalitati diferite (raze X, CT, RMN, microscopie, PET, SPECT, endoscopie, OCT si multe altele) sunt utilizate pentru a crea imagini medicale. Segmentarea imaginii este o ramura a procesarii digitale a imaginilor care se concentreaza pe impartirea unei imagini in diferite parti in functie de caracteristicile si proprietatile acestora. Scopul segmentarii este de a simplifica si/sau de a schimba reprezentarea unei imagini in ceva mai semnificativ si mai usor de analizat.

Segmentarea imaginilor medicale are un rol esențial în sistemele de diagnosticare asistate de computer în diferite aplicații. De ex, imparte o imagine în zone pe baza unei descrieri specificate, cum ar fi segmentarea organelor/țesuturilor corpului în aplicațiile medicale pentru detectarea granițelor, detectarea/segmentarea tumorii și detectarea în masă. O varietate de probleme de segmentare a imaginilor medicale prezintă provocări tehnice semnificative, inclusiv intensități eterogene ale pixelilor, limite zgomotoase/prost definite și forme.


## II. STATE OF THE ART & RELATED WORK

Brain Tumor Segmentation with Deep Neural Networks (<https://paperswithcode.com/paper/brain-tumor-segmentation-with-deep-neural>) In timp ce unele tumori, cum ar fi meningioma pot fi segmentate cu usurinta, altele precum glioma, sau glioblastoma sunt mult mai greu de localizat. Aceste tumori sunt de foarte multe ori difuze, slab contrastate si se extind prin structuri de tip tentacul care le fac greu de segmentat. Alta problema fundamentala care apare in timpul segmentarii este faptul ca tumorile pe creier pot aparea oriunde pe creier, luand orice forma.




Un creier sanatos este alcatuit, de obicei din 3 tipuri de tesuturi: materia alba, materia gri si fluidul cerebrospinal. Scopul segmentarii tumorilor pe creier este de a detecta locatiile si intinderea regiunilor de tumoare. Acest lucru este

realizat prin identificarea spatiilor anormale comparativ cu cele sanatoase. De obicei, conturul tumorilor este neclar si greu de distins de tesutul normal. Solutia pentru acest lucru vine prin folosirea a diverse functii de prelucrare a imaginilor care releva tumorile.




Brain Tumor Segmentation and Radiomics Survival Prediction: Contribution to the BRATS 2017 Challenge (<https://arxiv.org/pdf/1802.10508v1.pdf>) Evaluarea cantitativa a tumorilor pe creier ofera informatii valoroase si constituie o parte esentiala in procedurile de diagnosticare. Segmentarea automata este atractiva in acest context deoarece confera o alternativa mult mai rapida si obiectiva uneori chiar si mai precisa despre particularitatile relevante ale unor tumori. Din cauza iregularitatilor la nivelul naturii tumorilor, descrierea de algoritmi capabili sa segmenteze automat ramane insa o sarcina foarte dificila. Metode: Preprocesarea de date. Din cauza diferitelor valori ale intensitatilor aparatelor RMN, este absolut necesar sa cream un algoritm care poate procesa imagini provenite din mai multe surse.




Brain tumor segmentation based on deep learning and an attention mechanism using MRI multi-modalities brain images (<https://www.nature.com/articles/s41598-021-90428-8>)

Localizarea si segmentarea tumorilor pe creier din imaginile RMN sunt doua task-uri greu de realizat dar in acelasi timp si foarte importante avand aplicabilitate in domeniul analizei medicale. In acest articol vrem sa obtinem un sistem de segmentare a tumorilor, flexibil si eficient.



Astfel, propunem o preprocesare doar pe o parte mica a imaginii si nu pe imaginea in totalitate. Aceasta metoda scade timpul computational. Tumorile pe creier includ cele mai periculoase tipuri de tumori din lume. Glioma, cea mai comuna tumoare apare din cauza carcinogenezei celulelor gliale in maduva spinarii si in creier.



A Survey of Current Methods in Medical Image Segmentation (<https://www.ece.lsu.edu/gunturk/Topics/Segmentation-1.pdf>)

Diagnosticul imagistic este un instrument nepretuit in medicina zilelor noastre. Imagistica prin rezonanta magnetica (IRM), tomografia computerizata (CT), mamografia digitala si alte modalitati de imagistica ofera un mijloc eficient pentru cartografierea neinvaziva a anatomiei unui pacient. Aceste tehnologii ofera informatii despre anatomia pacientilor sanatosi cat si a celor bolnavi, foarte utile pentru cercetarea

medicala si reprezinta o componenta critica in diagnosticare si planificarea tratamentului. Odata cu cresterea dimensiunii si numarului de imagini medicale, utilizarea computerelor pentru a facilita procesarea si analiza lor a devenit necesara. In special, algoritmi pentru delimitarea structurilor anatomice si a altor regiuni de interes sunt o componenta cheie in asistarea si automatizarea sarcinilor radiologice specifice. Acesti algoritmi, numiti algoritmi de segmentare a imaginii, joaca un rol vital in numeroase domenii biomedicale, cum ar fi cuantificarea volumelor de tesut, localizarea patologiei, studiul structurii anatomice, planificarea tratamentului, corectia partiala a volumului datelor imagistice functionale si chirurgia computerizata.

PHiSeg: Capturing Uncertainty in Medical Image Segmentation (<https://link.springer.com/chapter/10.1007/978-3-030-32245-8-14>)


Segmentarea structurilor anatomice si a patologiilor este in mod inherent ambigua. De exemplu, marginile unei structuri pot sa nu fie clar vizibile sau diferiti experti pot avea stiluri diferite de adnotare. Majoritatea metodelor actuale de ultima generatie nu tin cont de astfel de ambiguitati, ci mai degrabă invata o singura mapare de la imagine la segmentare. In aceasta lucrare, este propusa o noua metoda de modelare a distributiei conditionale de probabilitate a segmentarilor in cazul unei imagini de intrare. Este dedus un model probabilistic ierarhic, in care bariabile latente separate sunt responsabile pentru modelarea segmentarii la rezolutii diferite. Inferenta in acest model poate fi efectuata eficient utilizand cadrul variational al autoencoderului. Se arata cum metoda propusa poate fi utilizata pentru a genera mostre de segmentare semnificativ mai realiste si mai diverse in comparatie cu lucrarile recente, atunci cand sunt antrenate cu adnotari de la un singur adnotator sau mai multi.

### III. METHOD DESCRIPTION

Aplicatia noastra realizeaza segmentarea imaginilor medicale, ce prezinta tumori cerebrale in diferite stagii si forme. Astfel, prelucram imaginea initiala si o aducem in diferite etape ale segmentarii. In implementarea finala, am utilizat doua abordari diferite ale algoritmului Watershed, oferind rezultate putin diferite.

Am utilizat pentru procesarea imaginilor facilitatile puse la dispozitie, in limbajul C++, de biblioteca OpenCV. Pentru al doilea algoritm am urmat pasii descrisi in laboratorul 12 la disciplina 'Prelucrarea imaginilor'. Conceptul de bazine hidrografice este bazat pe interpretarea imaginii sub forma unei suprafete topografice. In aceasta interpretare sunt considerate trei tipuri de puncte: (a) puncte de minim regional; (b) puncte in care, daca s-ar plasa o picatura de apa, aceasta s-ar scurge cu siguranta spre un singur punct de minim; si (c) puncte din care apa s-ar scurge cu probabilitate egala spre mai multe puncte de minim. Pentru o valoare de minim regional setul de puncte care satisfac conditia (b) se numeste bazin de colectare (eng. watershed) al aceluia minim. Punctele care satisfac conditia (c) formeaza cumpana apelor, crestele suprafetei topografice, si se numesc linii


de divizare (eng. watershed lines). Principalul obiectiv al algoritmilor de segmentare bazati pe aceste concepte este de a determina liniile de divizare (Figura 1). Cel mai rapid algoritm watershed este cel propus de Luc Vincent si de Pierre Soille, ilustrat in Figura 2 si de urmasorii pasi: Pasul 1: Se sorteaza toti pixelii din imagine in functie de intensitate. Odata sortati, se poate opera asupra pixelilor la niveluri succesive de gri, precum o inundatie ar progresa in imagine crescand odata cu nivelurile de gri. Pasul 2: Se determina pixelii cu cea mai mica valoare de gri din imagine Figura 2 (a). Pixelilor din fiecare vecinatate conectata li se asociaza o eticheta. Pasul 3: Pixelii sunt procesati in ordinea nivelurilor de gri. Pentru fiecare nivel de gri, pixelii care au vecini etichetati sunt adaugati intr-o coada cu prioritati ca in Figura 2 (b). Se determina eticheta pixelului din capul cozii pe baza vecinilor etichetati si se scoate pixelul din coada. Dupa procesarea tuturor pixelilor cu vecini etichetati, se proceseaza pixelii ramasi prin asocierea unei noi etichete ca in cazul bilei negre din Figura 2 (b). Pasul 4: Dupa etichetarea tuturor pixelilor, grantele obtinute intre regiunile cu etichete diferite reprezinta liniile de divizare (watersheds) ale imaginii. In Figura 2 (c) suprafata este divizata in patru regiuni si sunt detectate trei linii de divizare.




**Figura 2**

#### IV. PRELIMINARY RESULTS


In urmatoarele randuri va fi prezentat primul algoritm de tip watershed implementat. Ca exemplu, am luat imaginea din Fig. 1:



**Figura 1**



Indiferent daca imaginea vine sau nu deja in formatul acesta, mai intai realizam transformarea in grayscale (Fig. 2).



In acelasi timp, este de preferat utilizarea unui filtru gaussian pentru a inlatura zgomotul care ar putea aparea.

In urmatorul pas, se doreste binarizarea imaginii pentru a putea detecta marginile diferitelor tumori prezente (Fig. 3).



Acestea sunt mai apoi identificate si colorate pentru a face distinctia intre zonele si gruparile din care fac parte (Fig. 4).

Mai jos este prezentat codul corespunzator acestei etape a aplicatiei noastre impreuna cu rezultatul rularii acestuia. Se observa functiile specifice fiecarui pas si imaginile prelucrate.


```
int main()
{
    Mat img = imread("C:/Users/Radu/source/repos/PDM-Project/PDM-Project/Resources/brain-tumor-2.jpg", IMREAD_GRAYSCALE);
    if (img.empty())
    {
        cout << "Could not open or find the image" << endl;
        cin.get();
        return -1;
    }

    int w = img.cols;
    int h = img.rows;
    unsigned char* imgData = img.data;
    unsigned char* intermediary = processImage(imgData, w, h);
    unsigned char* trah = thresholdImage(intermediary, w, h);
    watershed(trah, w, h);


    Mat intermediaryMat(h, w, CV_8UC1, intermediary);
    Mat thresholdedMat(h, w, CV_8UC1, trah);

    imshow("Original Image", img);
    imshow("Preprocessed Image", intermediaryMat);
    imshow("Thresholded Image", thresholdedMat);

    waitKey(0);
    return 0;
}
```



In continuare, am aplicat o alta abordare a algoritmului watershed, compusa din 9 pasi care parcurg toate etapele necesare de pregatire a imaginii.



1) Realizarea unei segmentări grosiere a imaginii, folosind segmentarea cu prag (se poate utiliza metoda Otsu). Se observă că apar unele erori de segmentare: cavități în interiorului obiectelor și puncte singulare în exteriorul lor.

2) Corectarea erorilor de segmentare: vom folosi operațiile morfologice de închidere, pentru cavitățile interioare, respectiv deschidere pentru punctele exterioare.

3) Identificarea regiunilor care aparțin cu certitudine background-ului: realizăm o dilatare morfologică a imaginii obținute la punctul (2), în urma căreia contururile exterioare ale obiectelor vor fi ușor exagerate. Avem garanția ca restul regiunilor rămase aparțin background-ului. Ca element structural putem folosi un cerc de rază relativ mică.

4) Determinarea transformatei distanță: pentru fiecare pixel din imagine se determină distanța până la cel mai apropiat pixel de intensitate 0. Vom folosi funcția `distanceTransform`, cu parametrul `distanceType` de valoare `DIST L2`, aplicată pe negativul imaginii obținute la punctul (2).

5) Identificarea regiunilor care aparțin cu certitudine interioarelor obiectelor: Vom face o segmentare cu prag a transformatei distanță (funcția `threshold` cu ultimul parametru `THRESH BINARY`). Pragul poate fi, de exemplu, un procentaj din valoarea maximă a transformatei (eg.  $\max * 0.8$ ). Putem identifica valorile maxime și minime ale unei matrici folosind funcția `minMaxLoc`.


6) Separăm regiunile anterioare pe obiecte folosind funcția `connectedComponents` (vezi lab. anterioare). Funcția generează o matrice care conține valori de 0 pentru background și valori nenule pentru fiecare obiect conex identificat, în ordine ascendentă. Dacă dorim să afișăm aceste valori, le vom normaliza și le vom rescala în intervalul 0-255.

7) Din masca determinată la punctul (3) vom elimina regiunile obținute anterior. Rezultă astfel o mască ce conține regiunile de incertitudine. Se poate folosi funcția `setTo` : `matrice.setTo(valoare, condiție)`

8) Construim matricea completă a markerilor folosind rezultatele anterioare: - Adunăm valoarea 1 la toate elementele matricii de la punctul (6). Așadar, background-ul va avea valoarea 1, iar centrele obiectelor vor avea valorile

2, 3, etc. - În matricea astfel obținută, setăm pe 0 elementele care corespund regiunilor de incertitudine (regiunile cu valori nenule din matricea de la punctul (7); din nou putem folosi funcția `setTo`)

9) Acum putem utiliza funcția `watershed`. - funcția operează pe imagini RGB (cele utilizate până acum au fost grayscale), așadar prima dată convertim imaginea inițială în RGB (funcția `cvtColor` cu ultimul parametru `CV_GRAY2RGB`) - apelăm funcția `watershed`. Parametrii sunt imaginea în format RGB, respectiv matricea de markeri de la punctul (8) Funcția va modifica matricea de markeri și va seta elementele fiecărei regiuni identificate (regiunile corespunzătoare fiecărui "bazin") pe valori nenule. Pozițiile ce corespund marginilor bazinelor (contururile obiectelor identificate) vor fi setate pe -1. Putem folosi funcția `setTo`, aplicată imaginii inițiale, pentru a scoate în evidență aceste contururi. Imaginile de mai jos ilustrează rezultatul algoritmului.





## V. PRELIMINARY CONCLUSIONS

In concluzie, am reusit implementarea unui algoritm de tip watershed folosindu-ne de functii OpenCV, in doua moduri diferite, prima abordare axandu-se pe functia findContours, iar cea de-a doua pe connectedComponents. Ideea de baza pentru ambele consta in obtinerea unei matrice marker pentru folosirea un functia watershed din OpenCV, ca etapa finala a algoritmului. Este posibila dezvoltarea algoritmului pentru a oferi o mai buna acuratete in cazul imaginilor neclare sau de o calitate mai proasta, cat si optimizarea acestuia prin inlaturarea pasilor redundanti si alegerea unor algoritmi mai eficienti. De asemenea, in cazul ideal, imaginile date spre prelucrare ar avea aceeasi calitate astfel incat multitudinea de parametri care afecteaza algoritmul nu ar necesita modificari in functie de imaginea de intrare.

## REFERENCES

[1] <https://www.todaysoftmag.ro/article/3229/segmentarea-automata-in-imagistica-medicala>

Asuncion A, Newman DJ: UCI Machine Learning Repository. Irvine, CA: University of California, School of Information and Computer Science. Available at: <http://www.ics.uci.edu/mllearn/MLRepository.html> (2007)

Pitiot A, Toga AW, Thompson PM: Adaptive elastic segmentation of brain MRI via shapemodel-guided evolutionary programming. *IEEE Transactions on Medical Imaging* 21:910– 923 (2002)

Alexander, J.A. & Mozer, M.C. (1995) Template-based algorithms for connectionist rule extraction. In G. Tesauro, D.S. Touretzky and T.K. Leen (eds.), *Advances in Neural Information Processing Systems* 7, pp. 609–616. Cambridge, MA: MIT Press.

Bower, J.M. & Beeman, D. (1995) *The Book of GENESIS: Exploring Realistic Neural Models with the GEneral NEural SIEmulation System*. New York: TELOS/Springer–Verlag.